

Wine Classification

Pracownia Analizy Danych, czerwiec 2026

Martyna Pieczka, Magdalena Chamera

Wstęp

Dane można pobrać ze strony <https://archive.ics.uci.edu/dataset/109/wine>, interesuje nas plik wine.data. Nazwy kolumn nadajemy zgodnie z opisem zawartym w wine.names.

```
wine_df <- read.csv("wine.data", header=FALSE)

colnames(wine_df) <- c(
  "Class",
  "Alcohol",
  "Malic_acid",
  "Ash",
  "Alcalinity_of_ash",
  "Magnesium",
  "Total_phenols",
  "Flavanoids",
  "Nonflavanoid_phenols",
  "Proanthocyanins",
  "Color_intensity",
  "Hue",
  "OD280_OD315",
  "Proline"
)
```

W celu poprawnego wyświetlania polskich znaków na wykresach skorzystano z biblioteki showtext:

```
library(showtext)
```

Warning: package 'showtext' was built under R version 4.4.3

Loading required package: sysfonts

Loading required package: showtextdb

```
showtext_auto()
```

Wstępna analiza danych - opis struktur danych

UWAGA DO MADZI - aby stworzyć środowisko w .qmd należy użyć skrótu klawiszowego **ctrl+alt+i**, na macbook **cmd+option+i**. **WYBRANY KOLOR RAPORTU NA TEN MOMENT TO #6E1300, przypomina wino**

W trakcie wstępnej analizy danych postępowaliśmy następująco:

1. **Sprawdzenie brakujących wartości.** Zbiór danych ich nie ma.

```
colSums(is.na(wine_df))
```

Class	Alcohol	Malic_acid
0	0	0
Ash	Alcalinity_of_ash	Magnesium
0	0	0
Total_phenols	Flavanoids	Nonflavanoid_phenols
0	0	0
Proanthocyanins	Color_intensity	Hue
0	0	0
OD280_OD315	Proline	
0	0	


2. **Sprawdzenie zrównowazenia klas.** Żadna z klas nie dominuje nad resztą, choć liczebności nie są równe.

```
library(ggplot2)
```

Warning: package 'ggplot2' was built under R version 4.4.3

```
#tworzenie wykresu za pomocą ggplot2 - zliczanie

ggplot(wine_df, aes(x = Class, fill=as.factor(Class))) +
  geom_bar() +
  geom_text(stat = 'count', aes(label = after_stat(count)), vjust = -0.5) +
  #wykres źle się skalował w pdf - dodanie 15% wolnej przestrzeni nad słupkiem
  scale_y_continuous(expand = expansion(mult = c(0, 0.15))) +
  theme_minimal() +
  labs(title = "Rozkład klas w zbiorze Wine",
       x = "Klasa",
       y = "Liczba obserwacji",
       fill = "Klasa")
```



3. **Stworzenie wykresu korelacji.** Użyto metody sortowania hclust (hierarchikal clustering, które łączy zmienne w klastry na podstawie siły korelacji) wraz z dodawaniem trzech prostokątów. Wyodrębniono cztery grupy korelacji dodatnich, z czego najważniejsze są:

- klaster 1 (lewy górny róg):
 - zmienne *Hue*, *Proanthocyanins*, *OD280_OD315*, *Total_phenols*, *Flavanoids*
 - silna korelacja dodatnia, spowodowana zależnościami chemicznymi (flawonidy to związki z grupy polifenoli, wpływają na barwę i wynik testu OD280_OD315 na obecność białek i polifenoli).
- klaster 2:

- zmienne *Magnesium*, *Color_intensity*, *Alcohol*, *Proline*
- prolina jest aminokwasem znajdującym się w winogronach, którego stężenie wzrasta wraz z dojrzałością owoców. Przekłada się to na wyższy poziom cukru, w efekcie również alkoholu.

Klaster 3 i 4 są mniej istotne w analizie:

- klaster 3:
 - zmienne *Ash*, *Alcalinity_of_ash*
 - powiązane parametry (*Ash* to sucha pozostałość po całkowitym spaleniu substancji organicznych w próbce. Składa się ze związków mineralnych. *Alcalinity_of_ash* mierzy zasadowość popiołu).
- klaster 4:
 - zmienne *Malic_acid*, *Nonflavanoid_phenols*
 - *Malic_acid*, czyli kwas jabłkowy, odpowiada za kwasowość wina, jego poziom spada w wyniku dojrzewania winogron na słońcu
 - DO CZYTAĆ - ZOBACZYĆ STR XXII W KSIĄŻCE

Ponadto, z klastrow można wyciągnąć następujące wnioski:


- Silne korelacje (zwłaszcza w klastrze 1) -> **warto zastosować PCA** przed tworzeniem modelu LDA.
- Drzewo decyzyjne najprawdopodobniej wybierze jako korzeń tylko jedną zmienną z pierwszego klastru - reszta nie wniesie żadnej nowej informacji.
- Ponieważ zmienne są skorelowane i opisują różne cechy w różnych jednostkach, należy wykonać **standaryzację danych** przed modelowaniem kNN.

```
library(corrplot)
```

```
corrplot 0.95 loaded
```

```
korelacje_wine <- cor(wine_df[, -1]) #wykluczamy kolumnę Class - zmienna dyskretna

corrplot(korelacje_wine,
  method = "circle",
  order = "hclust",
  addrect = 4,
  col = COL2("RdYlBu"),
  tl.srt = 45
)
```



4. Wykresy rozkładów zmiennych. Można na ich podstawie wyznaczyć parametry, które izolują dane klasy:


- *Proline* ma znacznie wyższe wartości w **klasie 1** w porównaniu z pozostałymi klasami. *Malic_acid* ma bardzo niską wariancję dla klasy 1.
- *Alcohol*, *Color_intensity* są najniższe w **klasie 2**.
- W **klasie 3**, *Flavanoids*, *Hue*, *Total_Phenols* i *OD280_OD315* mają niskie wartości tych parametrów.

```
library(tidyr) #POTRZEBNY KOMENTARZ DO WYKRESU

#dane w formacie długim - potrzebne do wygenerowania wielu wykresów
wine_long <- pivot_longer(wine_df,
                           cols = -Class,
                           names_to = "Variable",
                           values_to = "Value")

ggplot(wine_long, aes(x = Value, fill = as.factor(Class), group = as.factor(Class))) +
  geom_density(alpha = 0.4) +
  facet_wrap(~Variable, scales = "free") +
  theme_minimal() +
```

```
labs(title = "Rozkłady cech fizykochemicznych w podziale na klasy win",
     x = "Wartość",
     y = "Gęstość",
     fill = "Klasa")
```




5. Wartości odstające.

- naruszone zostały założenia LDA o zbliżonej wariancji i braku wartości odstających. Macierze kowariancji mogą być zaburzone.
- klasy są od siebie fizycznie odseparowane (np. dla parametru *Flavanoids*), zatem model kNN oparty na odległościach, czy też drzewo decyzyjne oparte na regułach, znajdą czyste granice podziału dla tych zmiennych.

```
ggplot(wine_long, aes(x = as.factor(Class), y = Value, fill = as.factor(Class))) +
  geom_boxplot(outlier.colour = "#6E1300", outlier.shape = 16, outlier.size = 2) +
  facet_wrap(~Variable, scales = "free") +
  theme_minimal() +
  labs(title = "Analiza wartości odstających w podziale na klasy",
       x = "Klasa",
       y = "Wartość",
       fill = "Klasa")
```

Analiza wartości odstających w podziale na klasy



Przygotowanie danych

- standaryzacja danych
- przed PCA PODZIAŁ NA ZBIÓR UCZĄCY I TESTOWY - bo inaczej data leakage
- PCA (ma być nieparzyste)

Tworzenie modeli

- LDA (ew. QDA, RDA)
- kNN zoptymalizowany za pomocą krosvalidacji
- drzewo decyzyjne

UWAGA NA OVERFITTING!

Drzewo decyzyjne


```
library(rpart)
library(rpart.plot)
```

Warning: package 'rpart.plot' was built under R version 4.4.3

```
#as.factor - drzewo klasyfikujące a nie regresyjne
model_drzewa <- rpart(as.factor(Class) ~ .,
                      data = wine_df,
                      method = "class")

rpart.plot(model_drzewa,
            type = 2,                #warunki podziału nad węzłami
            extra = 104,             #pokazuje klasę, prawdopodobieństwo i % obserwacji w węźle
            box.palette = "auto",
            nn = TRUE,               #numery węzłów
            main = "Drzewo decyzyjne dla zbioru danych Wine")
```

Drzewo decyzyjne dla zbioru danych Wine



DO ZROBIENIA

- Martyna
 - ZMIENIĆ KOLEJNOŚĆ W EDA
 - pomyśleć nad opisem chemicznym - czy potrzebny?
 - wnioski z wartości odstających dodać źródła
 - drzewo decyzyjne poprawić kolory i komentarze i optymalizacja

- bagging drzew!
- kolejność - oddzielamy, potem standaryzacja recipes
- KNN - jakieś manipulacje innymi rzeczami niż K
- popranwie metodologicznie
- dobra interpretacja, np. czy zwracają uwagę na inne cechy, accuracy, czy się wszystkie mylą na tych samych obserwacjach

PONADTO - UWAGI PROWADZĄCEGO

- Raport - może podobny do samego artykułu naukowego, a może po prostu tutaj cały kod z `#| echo: false`
- Raport w LATEX
- modele omawiane na zajęciach - git
- UZASADNIENIE DECYZJI METODOLOGICZNYCH (w zasadzie wszystkiego - wybór miary dopasowania, schemat krosvalidacji itp)
- Więcej nie znaczy lepiej!