

Porównanie modeli klasyfikacyjnych dla zbioru Wine

Martyna Pieczka, Magdalena Chamera

1 Wstęp

Celem niniejszego raportu jest podsumowanie trzech modeli klasyfikacyjnych utworzonych na podstawie danych *Wine recognition data*¹, zawierających 13 parametrów fizykochemicznych win powstałych z trzech typów winogron w tym samym regionie Włoch.

Oficjalna dokumentacji UCI nie podaje jednostek miar. Zbiór może jednak wciąż być używany do testowania metod klasyfikacji.

2 Metodologia

2.1 Podział danych i schemat walidacji

W celu obiektywnej oceny zdolności generalizacyjnych modeli, zbiór danych został podzielony na dwie rozłączne części: **zbiór uczący (70%)** oraz **zbiór testowy (30%)**.

Ze względu na planowany tuning hiperparametrów, na zbiorze uczącym zastosowano schemat **10-krotnej kroswalidacji (10-fold Cross-Validation)**.

Szczególną uwagę zwrócono na wyeliminowanie ryzyka wycieku danych (*data leakage*). Wszelkie transformacje (takie jak standaryzacja czy redukcja wymiarowości) były uczone i wyliczane **wyłącznie na 9 foldach treningowych** w każdej iteracji, a następnie jedynie aplikowane na 1 foldzie walidacyjnym. Analogiczne podejście zastosowano dla końcowego zbioru testowego – został on przetransformowany przy użyciu średnich i odchyłeń standardowych wyliczonych wyłącznie na pełnym zbiorze uczącym. Dzięki temu zbiór walidacyjny i testowy dopasowują się do skali, której nauczył się model, zachowując pełną izolację informacji.

¹Aeberhard, S. & Forina, M. (1992). Wine [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5PC7J>

2.2 Uzasadnienie wyboru modeli

W badaniu wykorzystano trzy różne podejścia do klasyfikacji, z których każde wymagało odpowiedniego przygotowania danych wejściowych. Poniżej przedstawiamy uzasadnienie wyboru danego modelu oraz transformacje przeprowadzone na danych.

- **k-Najbliższych Sąsiadów (kNN):**

Model nieparametryczny oparty na odległości euklidesowej. Ze względu na wrażliwość algorytmu na skale zmiennych oraz kłutwą wymiarowości, dane wejściowe poddano standaryzacji, a następnie zredukowano ich wymiar za pomocą PCA (do 5 składowych), co wyjaśnia ok. 80% całkowitej wariancji zbioru i pozwala zredukować wymiar, odrzucając jedynie szum informacyjny. W procesie krosvalidacji przeprowadzono dwuwymiarowy tuning hiperparametrów: optymalizowano liczbę sąsiadów k (w zakresie 1–25) oraz rodzaj funkcji jądrowej (kernel), co pozwoliło na uelastycznienie granic decyzyjnych klasyfikatora.

- **Linowa Analiza Dyskryminacyjna (LDA):**

Zbiór danych Wine charakteryzuje się niską liczbą obserwacji, a na podstawie wstępnej analizy (w tym wykresu rzutu na dwie pierwsze składowe PCA) można wnioskować, że klasy są odseparowane geometrycznie. Przyjęto założenia - rozkład predyktorów wewnątrz każdej klasy jest zbliżony do rozkładu normalnego oraz rozkłady mają taką samą wariancję, różniąc się jedynie średnimi.

W pierwotnej fazie projektu dane wejściowe dla modelu LDA poddano transformacji PCA (analogicznie jak w przypadku kNN). Warto jednak wspomnieć, **wstępne stosowanie PCA dla algorytmu LDA jest teoretycznie nieefektywne**. LDA samodzielnie wyznacza optymalne hiperpłaszczyzny rozdzielające. Ostatecznie zdecydowano się na przeprowadzenie eksperymentu numerycznego - pętli walidacyjnej poddano tuningowi liczbę składowych głównych PCA przekazywanych do modelu LDA (testując zakres od 2 do 13 składowych).

- **Drzewo decyzyjne:**

Dla zbioru danych Wine, charakteryzującego się predyktorami o skrajnie zróżnicowanych przedziałach liczbowych (od ułamkowych zawartości fenoli po tysięczne wartości proliny), model ten zastosowano ze względu na jego naturalną zdolność do bezpośredniej pracy na cechach o różnych skalach bez ryzyka dominacji jednych zmiennych nad innymi, co pozwoliło całkowicie pominąć etap standaryzacji i PCA. Podejście zespołowe wybrano po to, by sprawdzić skuteczność nieliniowych, ortogonalnych podziałów w surowej przestrzeni cech. Zastosowanie baggingu (bootstrap replications = 100) miało na celu uśrednienie wyników wielu głębokich, celowo przeuczonych drzew składowych, co drastycznie obniżyło wariancję modelu i zapewniło stabilność predykcji przy małej liczbie obserwacji.

W celu optymalizacji struktury drzew w komitecie przeprowadzono dwuwymiarowy tuning siatki parametru złożoności (*cp*) oraz minimalnej liczby obserwacji do podziału (*minsplit*).

3 Wyniki analizy struktury danych Wine

3.1 Sprawdzenie brakujących wartości i zrównoważenia klas.

Zbiór danych nie ma brakujących wartości. Jest stosunkowo zbalansowany, z lekką dominacją klasy 2 (71 obserwacji), 59 obserwacjami w klasie 2 i najmniejszą reprezentacją klasy 3 (48 obserwacji). Ta proporcja uzasadnia wybór celności (Accuracy) jako odpowiedniej miary oceny jakości modeli.

3.2 Badanie rozkładów i wartości odstających zmiennych.


Na podstawie rozkładów można wyznaczyć parametry, które izolują dane klasy:

- *Proline* ma znacznie wyższe wartości w **klasie 1** w porównaniu z pozostałymi klasami. *Malic_acid* ma bardzo niską wariancję dla klasy 1.
- *Alcohol*, *Color_intensity* są najniższe w **klasie 2**.
- W **klasie 3**, *Flavanoids*, *Hue*, *Total_Phenols* i *OD280_OD315* mają niskie wartości tych parametrów.

Badanie wartości odstających daje następujące wnioski:

- Naruszone zostały założenia LDA o zbliżonej wariancji i braku wartości odstających. Macierze kowariancji mogą być zaburzone.
- Klasy są od siebie fizycznie odseparowane (np. dla parametru *Flavanoids*), zatem model kNN oparty na odległościach, czy też drzewo decyzyjne oparte na regułach, znajdują czyste granice podziału dla tych zmiennych.

Analiza wartości odstających w podziale na klasy



3.3 Wykres korelacji

Użyto metody sortowania hclust (hierarchical clustering, które łączy zmienne w klastry na podstawie siły korelacji) wraz z dodawaniem czterech prostokątów. Wyodrębniono cztery grupy korelacji dodatnich, z czego najważniejsze są:

- Klaster 1 (lewy górny róg):
 - Zmienne *Hue*, *Proanthocyanins*, *OD280_OD315*, *Total_phenols*, *Flavanoids*;
 - Silna korelacja dodatnia, spowodowana zależnościami chemicznymi (flawonidy to związki z grupy polifenoli, wpływają na barwę i wynik testu OD280_OD315 na obecność białek i polifenoli).
- Klaster 2:
 - Zmienne *Magnesium*, *Color_intensity*, *Alcohol*, *Proline*;
 - Prolina jest aminokwasem znajdującym się w winogronach, którego stężenie wzrasta wraz z dojrzałością owoców. Przekłada się to na wyższy poziom cukru, w efekcie również alkoholu.

Klaster 3 i 4 są mniej istotne w analizie:

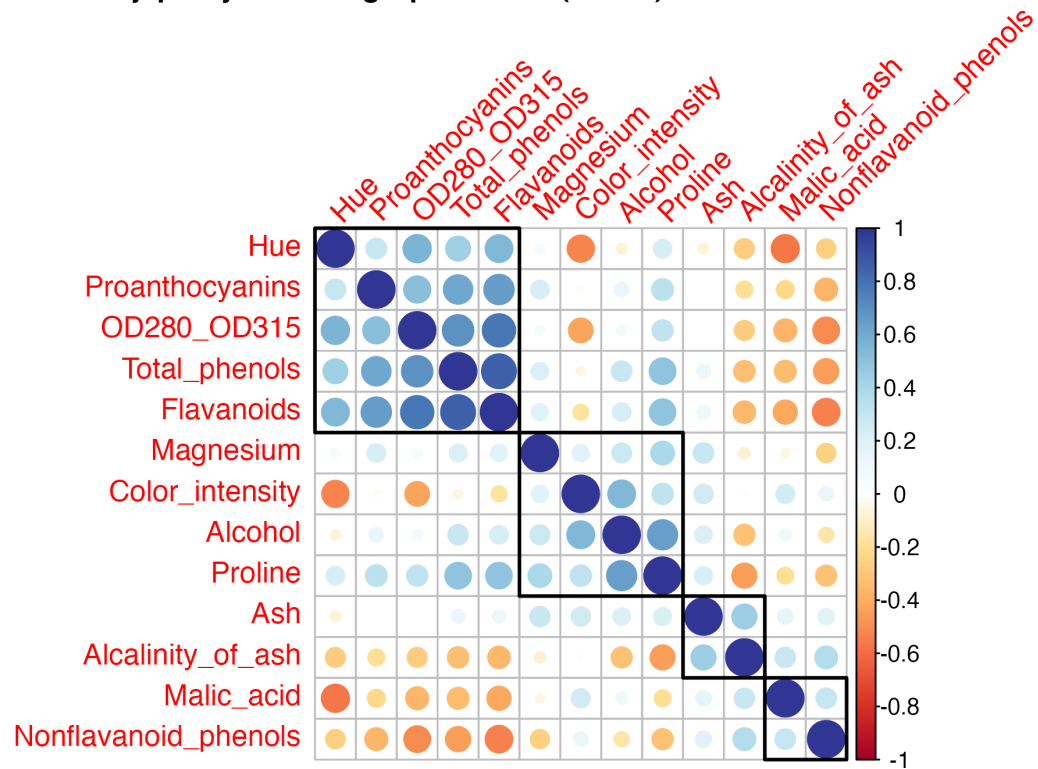
- Klaster 3:
 - Zmienne *Ash*, *Alcalinity_of_ash*;
 - Powiązane parametry (*Ash* to sucha pozostałość po całkowitym spaleniu substancji organicznych w próbce. Składa się ze związków mineralnych. *Alcalinity_of_ash* mierzy zasadowość popiołu).
- klaster 4:
 - Zmienne *Malic_acid*, *Nonflavanoid_phenols*;
 - *Malic_acid*, czyli kwas jabłkowy, odpowiada za kwasowość wina, jego poziom spada w wyniku dojrzewania winogron na słońcu

Ponadto, z klastrów można wyciągnąć następujące wnioski:

- Silne korelacje (zwłaszcza w klastrze 1) sugerują, że **warto zastosować PCA**.
- Drzewo decyzyjne najprawdopodobniej wybierze jako korzeń tylko jedną zmienną z pierwszego klastru - reszta nie wniesie żadnej nowej informacji.

- Ponieważ zmienne są skorelowane i opisują różne cechy w różnych jednostkach, należy wykonać **standaryzację danych** przed modelowaniem kNN.

Macierz korelacji predyktorów z grupowaniem (hclust)




3.4 Wizualizacja struktury danych w przestrzeni PCA

Potwierdzeniem potencjału klasyfikacyjnego analizowanego zbioru jest rzut obiektów na przestrzeń dwóch pierwszych składowych głównych (PC1 i PC2). Jak przedstawiono na wykresie, transformacja nienadzorowana pozwala na ujawnienie naturalnej separacji geometrycznej trzech klas win. Powstałe klastry uzasadniają prognozowaną wysoką skuteczność dla modeli kNN i LDA. Jednocześnie z uwagi na diagonalne ułożenie klastrów, przewidywany jest niższy wynik Accuracy dla drzew decyzyjnych, które dokonują podziałów ortogonalnie.

Wizualizacja zbioru Wine w przestrzeni dwóch pierwszych składowych głównych (PCA)

Wyraźna separacja geometryczna klas wyjaśnia wysoką skuteczność modeli kNN i LDA



4 Interpretacja modeli

W tej części raportu zostanie podsumowana praca badanych modeli: kNN, LDA oraz drzewa decyzyjnego z baggingiem. Cały proces oceny ułożyliśmy w logiczną całość, tj. zaczynamy od pokazania, jak przebiegał tuning hiperparametrów, następnie sprawdzamy stabilność algorytmów podczas 10-krotnej krosvalidacji, a na koniec oceniamy ich ostateczną skuteczność na odizolowanym zbiorze testowym.

Wstępne podsumowanie optymalizacji i krosvalidacji pokrywają się z wnioskami z analizy struktury danych:

- **kNN oraz LDA** osiągnęły średnią dokładność na poziomie odpowiednio **98.33%** (dla $k = 9$ i jądra Epanechnikova) oraz **98.40%** (przy wykorzystaniu wszystkich 13 składowych PCA). Modele te w większości foldów działały bezbłędnie, co potwierdza, że geometryczna separacja klas w przestrzeni cech bardzo im sprzyja.
- **Drzewo decyzyjne (bagging)** radzi sobie słabiej, uzyskując średnie Accuracy na poziomie **92.67%** (dla parametrów $cp = 0.005$ oraz $minsplit = 3$). Co więcej, wyniki z poszczególnych przebiegów pętli pokazują, że model ten ma dużą wariancję - jego dokładność potrafi skoczyć do idealnego 100%, aby w innym foldzie spaść do poziomu poniżej 85%.

Poniżej szczegółowo rozbijamy te wyniki na poszczególne etapy analizy.

4.1 Proces optymalizacji i tuning hiperparametrów

Aby uniknąć przypadkowego doboru parametrów i uzyskać największą dokładność, każdy z trzech algorytmów został poddany tuningowi na siatce parametrów (*Grid Search*) wewnątrz pętli 10-krotnej krosvalidacji. Oto jak parametry wpływały na zachowanie poszczególnych modeli:

- **k-Najbliższych Sąsiadów (kNN):**

Wybór małej liczby sąsiadów ($k = 1$ lub $k = 3$) dawał najslabsze wyniki, ponieważ model był wtedy zbyt wrażliwy na lokalny szum w danych. Celność wyraźnie rośnie od $k = 5$, a swój szczyt osiąga **dla $k = 9$ przy użyciu jądra Epanechnikova (Accuracy: 0.9833)**. Wykres profilu pokazuje też, że dla małych k wybór funkcji odległości miał znacznie większe znaczenie, niż dla dużych k .


- **Liniowa Analiza Dyskryminacyjna (LDA):**

W tym przypadku sprawdzaliśmy, jak na model wpływa liczba składowych głównych PCA. Dla 2 lub 3 składowych celność była najniższa (poniżej 0.955), co oznacza, że odrzucaliśmy wtedy zmienne niosące kluczowe informacje. Wyraźny skok widać przy 5 składowych, a ostateczny najlepszy wynik uzyskujemy przy **13 składowych (Accuracy: 0.984)**. Potwierdza to wcześniejszą intuicję: obcinanie wymiarowości za pomocą PCA przed uruchomieniem LDA nie miało tutaj sensu matematycznego. LDA najlepiej poradziło sobie samo, mając do dyspozycji pełen zestaw surowych danych.

- **Drzewo decyzyjne (Bagging):**

Profil tuningu drzew ma najbardziej poszarpany i nieregularny przebieg, co wynika z natury algorytmów regułowych na małej próbie. Najlepszy wynik (**0.9267**) uzyskaliśmy dla bardzo niskich obostrzeń: $cp = 0.005$ oraz $minsplit = 3$. Potwierdza to teorię baggingu - pojedyncze drzewa składowe w komitecie powinny być jak najgłębsze i celowo przeuczone, ponieważ ich wariancję i tak skutecznie zbije późniejsze uśrednianie wyników. Z kolei zbyt mocne zwiększanie parametru złożoności ($cp \geq 0.03$) powodowało zbyt agresywne przycinanie gałęzi, co wprowadzało model w stan niedouczenia (*underfitting*) i blokowało celność na poziomie około 0.90.

Bezpośrednie zyski z przeprowadzonego procesu dobrze obrazuje wykres słupkowy „Przed i po tuningu”. Zbiór *Wine* jest prostym geometrycznie zbiorem, przez co nawet modele z parametrami bazowymi startowały z bardzo wysokiego pułapu (powyżej 90%). Mimo to, precyzyjne przeszukanie siatki pozwoliło urwać dodatkowe ułamki procentów celności dla każdego algorytmu. Najważniejszym zyskiem z tuningu nie jest jednak sam wzrost średniej, ale upewnienie się, że modele działają w swoich optymalnych i stabilnych konfiguracjach, co ma kluczowe znaczenie dla ich zachowania na zbiorze testowym.




Wpływ optymalizacji hiperparametrów na dokładność modeli

kNN (bazowe k=5 -> opt. k=9) | Drzewo (bazowe cp=0.01, minsplit=20 -> opt. cp=0.005, minsplit=3)

LDA (PCA=5 -> opt. PCA=13)

Stan modelu Przed tuningiem Po tuningu




4.2 Ocena stabilności i wyniki krosvalidacji

Po ustaleniu optymalnych hiperparametrów, dokładna ocena zachowania modeli na danych treningowych została przeprowadzona przy użyciu pełnych wyników 10-krotnej krosvalidacji. Analiza ta pozwala ocenić nie tylko ogólną skuteczność, ale przede wszystkim stabilność algorytmów przy zmianie podpróbek danych.

Rozkład dokładności w 10-krotnej krosvalidacji

Węższe pudełko oznacza większą stabilność modelu na różnych podpróbkach



Głównym wnioskiem płynącym z analizy rozkładu celności jest **różnica w wariancji modeli**:


- **LDA i kNN wykazują ekstremalną stabilność.** Pojedyncze punkty odstające na poziomie ok. 0.92 reprezentują foldy, w których algorytmy pomyliły się o jedną obserwację.
- **Drzewo decyzyjne (bagging) charakteryzuje się bardzo wysoką wariancją.** Szerokie pudełko (od 0.91 do 0.98) oraz długi dolny wąs sięgający wartości 0.83 pokazują, że model ten jest silnie uzależniony od losowego składu podpróbek walidacyjnych. Ze względu na małą liczebność pojedynczego foldu (ok. 12 obserwacji), ortogonalne cięcia przestrzeni przez drzewa okazały się mało odporne na zmienności wartości.

4.2.1 Mapa błędów klasyfikacji

Aby zrozumieć mechanizm potknięć poszczególnych algorytmów, wyizolowano i przeanalizowano wyłącznie te obserwacje z pętli krosvalidacji, na których pomylił się minimum jeden model.

Mapa błędów na poszczególnych obserwacjach

Wyświetlono tylko obserwacje, na których pomylił się minimum jeden model



Wizualizacja ta ujawnia unikalne cechy geometryczne klasyfikatorów oraz obrazuje różnice w ich stabilności:

- **Dominacja błędów drzewa decyzyjnego:** w pierwszej kolejności widać wyraźnie, że przeważająca większość czerwonych kafelków należy do drzewa. Wina o numerach 24, 25, 44, 67, 74, 82, 84, 119 i 151 zostały bezbłędnie sklasyfikowane przez modele kNN i LDA, podczas gdy drzewo przypisało je do złych klas. Potwierdza to wcześniejszy wniosek z wykresów pudełkowych – ortogonalne cięcia przestrzeni słabo radzą sobie z wyznaczaniem płynnych granic dla tego zbioru.
- **Rozbieżność w trudnych przypadkach (wina nr 26 i 62):** szczególnie ciekawe są obserwacje, przy których potknęły się jednocześnie dwa algorytmy o zupełnie innej charakterystyce:
 - Dla wina nr **62** zawiodło zarówno drzewo decyzyjne, jak i globalny model LDA, natomiast kNN zidentyfikował je poprawnie. Świadczy to o nietypowym ułożeniu tego punktu, które wymagało elastyczności algorytmu opartego na najbliższym sąsiedztwie.
 - Z kolei w przypadku wina nr **26** zawiodło drzewo i kNN, podczas gdy liniowa płaszczyzna dyskryminacyjna LDA okazała się trafna.

- **Odosobnione potknięcia najlepszych modeli:** nawet wiodące algorytmy mają swoje słabe punkty. LDA jako jedyny pomylił się przy obserwacji 97, natomiast kNN jako jedyny błędnie sklasyfikował wino nr 135.


5 Ocena końcowa na zbiorze testowym

Ostatnim etapem analizy jest weryfikacja zdolności generalizacyjnych zoptymalizowanych modeli na odizolowanym zbiorze testowym, stanowiącym 30% pierwotnych danych. Zgodnie z przyjętą metodologią, zbiór ten nie brał udziału w procesie treningu ani tuningu hiperparametrów. Aby uniknąć wycieku danych (*data leakage*), parametry standaryzacji oraz składowe PCA zostały wyliczone wyłącznie na podstawie pełnego zbioru uczącego, a następnie zaaplikowane na zbiorze testowym za pomocą funkcji projekcji.

5.1 Wyniki klasyfikacji

Modele przetrenowane na pełnym zbiorze treningowym (z wykorzystaniem najlepszych wyłoniętych hiperparametrów) poddano ostatecznemu egzaminowi. Wyniki celności (*Accuracy*) kształtują się następująco:

Porównanie Macierzy Pomyłek na zbiorze testowym



- Model kNN: osiągnął dokładność na poziomie 96.36%, co potwierdza jego wysoką skuteczność i brak zjawiska przeuczenia. Geometria klas w przestrzeni PCA okazała się na tyle stabilna, że granice decyzyjne skutecznie odseparowały nowe, nieznane przypadki.
- Model LDA: uzyskał dokładność 98.18%. Oznacza to, że założenie o liniowej separowalności klas przy użyciu 13 składowych PCA było trafne, a model bardzo dobrze uogólnia wiedzę.

- Drzewo decyzyjne (Bagging): osiągnęło dokładność na poziomie 96.36%. Mimo obaw o wyższą wariancję z etapu krosvalidacji, zastosowanie agregacji (baggingu) wygładziło ortogonalne podziały i zrównało ten algorytm skutecznością z pozostałymi metodami.

Wszystkie trzy modele radzą sobie na zbiorze testowym praktycznie tak samo dobrze. Zbliżone wyniki dowodzą, że proces optymalizacji hiperparametrów przebiegł prawidłowo, granice decyzyjne algorytmów są stabilne, a początkowa ocena na zbiorze walidacyjnym była w pełni rzetelna.

6 Wnioski końcowe

Przeprowadzona analiza dowodzi, że zbiór danych Wine charakteryzuje się wyraźną separowalnością klas, co pozwoliło wszystkim zastosowanym algorytmom osiągnąć bardzo wysoką celność na zbiorze testowym (powyżej 96%). Mimo zbliżonych wyników, zwycięzcą i ostatecznie rekomendowanym modelem spośród trzech poddanych analizie zostaje **LDA**.

Za wyborem LDA przemawia jego stabilność wykazana w krosvalidacji oraz prostota matematyczna. Algorytm ten idealnie wykorzystał naturalną, liniową geometrię rozkładu predyktorów. W przeciwieństwie do drzew decyzyjnych, LDA nie wymagało stosowania złożonego komitetu (baggingu) w celu redukcji wariancji. Z kolei w porównaniu do kNN, LDA tworzy globalne hiperpłaszczyzny decyzyjne, co czyni model znacznie lżejszym i szybszym w środowisku produkcyjnym, ponieważ eliminuje konieczność każdorazowego przeliczania odległości dla nowych obserwacji.