

Wine Classification Report

Martyna Pieczka, Magdalena Chamera

Wstęp

Celem niniejszego raportu jest podsumowanie trzech modeli klasyfikacyjnych utworzonych na podstawie danych *Wine recognition data*¹, zawierającym 13 parametrów fizykochemicznych win powstałych z trzech typów winogron w tym samym regionie Włoch.

Oficjalna dokumentacji UCI nie podaje jednostek miar. Zbiór może jednak wciąż być używany do testowania metod klasyfikacji, zwłaszcza z powodu wykonanej standaryzacji (z-score) danych, co usuwa wpływ jednostek na wyniki algorytmów.

Źródła

- (a) Forina, M. et al, PARVUS - An Extendible Package for Data” Exploration, Classification and Correlation. Institute of Pharmaceutical” [7] ” and Food Analysis and Technologies, Via Brigata Salerno, 16147 Genoa, Italy.
- (b) Stefan Aeberhard, email: stefan@coral.cs.jcu.edu.au”
- (c) July 1991”

Metodologia

1. Wstępna analiza danych (EDA)

Prace nad modelowaniem poprzedzono dogłębną eksploracją zbioru danych, aby zrozumieć jego strukturę i zidentyfikować potencjalne problemy. W ramach analizy zrealizowano następujące kroki:

- **Weryfikacja braków danych:** Sprawdzono kompletność zbioru, aby uniknąć błędów w działaniu algorytmów.
- **Analiza zmiennej celu:** Zweryfikowano stopień zrównoważenia klas, co jest kluczowe dla wyboru odpowiednich miar oceny modeli (np. Accuracy).

¹Aeberhard, S. & Forina, M. (1992). Wine [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5PC7J>

- **Badanie rozkładów i wartości odstających:** Przeanalizowano kształt rozkładów poszczególnych predyktorów oraz zidentyfikowano wartości odstające (outliery), które mogą negatywnie wpływać na wrażliwe modele.
- **Macierz korelacji:** Zbadano siłę zależności liniowych między zmiennymi objaśniającymi, w celu detekcji współliniowości.

2. Podział danych i schemat walidacji

W celu obiektywnej oceny zdolności generalizacyjnych modeli, zbiór danych został podzielony na dwie rozłączne części: **zbiór uczący (70%)** oraz **zbiór testowy (30%)**.

Ze względu na planowany tuning hiperparametrów, na zbiorze uczącym zastosowano schemat **10-krotnej kroswalidacji (10-fold Cross-Validation)**.

Szczególną uwagę zwrócono na wyeliminowanie ryzyka wycieku danych (*data leakage*). Wszelkie transformacje (takie jak standaryzacja czy redukcja wymiarowości) były uczone i wyliczane **wyłącznie na 9 foldach treningowych** w każdej iteracji, a następnie jedynie aplikowane na 1 foldzie walidacyjnym. Analogiczne podejście zastosowano dla końcowego zbioru testowego – został on przetransformowany przy użyciu średnich i odchyłeń standardowych wyliczonych wyłącznie na pełnym zbiorze uczącym. Dzięki temu zbiór walidacyjny i testowy dopasowują się do skali, której nauczył się model, zachowując pełną izolację informacji.

3. Algorytmy predykcyjne i transformacje

W badaniu wykorzystano trzy różne podejścia do klasyfikacji, z których każde wymagało odpowiedniego przygotowania danych wejściowych:

- **k-Najbliższych Sąsiadów (kNN):**

Algorytm oparty na pomiarze odległości euklidesowej, silnie wrażliwy na różnice w rzędach wielkości zmiennych oraz tzw. kłutwę wymiarowości. Z tego powodu dane wejściowe poddano **standaryzacji**, a następnie zredukowano przestrzeń cech za pomocą **Analizy Głównych Składowych (PCA)**. Model był poddany optymalizacji, w ramach której tuningowano hiperparametr k (liczbę rozpatrywanych sąsiadów).

- **Liniowa Analiza Dyskryminacyjna (LDA):**

Podobnie jak w przypadku kNN, model LDA jest wrażliwy na współliniowość i skalę, dlatego zasilony został danymi po wcześniejszej standaryzacji oraz transformacji PCA.

- **Drzewo decyzyjne:**


Dzięki specyfice algorytmów opartych na podziałach węzłów (niewrażliwość na monotoniczne transformacje i różnice w skalach), zrezygnowano ze standaryzacji oraz PCA. Model trenowano na **surowych danych**. W celu zabezpieczenia modelu przed przeuczeniem (*overfittingiem*), przeprowadzono tuning parametru złożoności drzewa (cp).

Analiza struktury danych Wine

W trakcie wstępnej analizy danych postępowaliśmy następująco:

1. **Sprawdzenie brakujących wartości.** Zbiór danych ich nie ma.
2. **Sprawdzenie zrównoważenia klas.** Rozkład liczebności klas w zbiorze Wine. Zbiór jest stosunkowo zbalansowany, z lekką dominacją klasy 2 (71 obserwacji) i najmniejszą reprezentacją klasy 3 (48 obserwacji). Ta proporcja uzasadnia wybór celności (Accuracy) jako odpowiedniej miary oceny jakości modeli.

Rozkład klas w zbiorze Wine



3. **Stworzenie wykresu korelacji.** Użyto metody sortowania hclust (hierarchichal clustering, które łączy zmienne w klastry na podstawie siły korelacji) wraz z dodawaniem trzech prostokątów. Wyodrębiono cztery grupy korelacji dodatnich, z czego najważniejsze są:
 - klaster 1 (lewy górny róg):
 - zmienne *Hue*, *Proanthocyanins*, *OD280_OD315*, *Total_phenols*, *Flavanoids*
 - silna korelacja dodatnia, spowodowana zależnościami chemicznymi (flawonidy to związki z grupy polifenoli, wpływają na barwę i wynik testu OD280_OD315 na obecność białek i polifenoli).
 - klaster 2:
 - zmienne *Magnesium*, *Color_intensity*, *Alcohol*, *Proline*

- prolina jest aminokwasem znajdującym się w winogronach, którego stężenie wzrasta wraz z dojrzałością owoców. Przekłada się to na wyższy poziom cukru, w efekcie również alkoholu.


Klaster 3 i 4 są mniej istotne w analizie:

- klaster 3:
 - zmienne *Ash*, *Alcalinity_of_ash*
 - powiązane parametry (*Ash* to sucha pozostałość po całkowitym spaleniu substancji organicznych w próbce. Składa się ze związków mineralnych. *Alcalinity_of_ash* mierzy zasadowość popiołu).
- klaster 4:
 - zmienne *Malic_acid*, *Nonflavanoid_phenols*
 - *Malic_acid*, czyli kwas jabłkowy, odpowiada za kwasowość wina, jego poziom spada w wyniku dojrzewania winogron na słońcu
 - **DOCZYTAĆ - ZOBACZYĆ STR XXII W KSIĄŻCE**

Ponadto, z klastrów można wyciągnąć następujące wnioski:

- Silne korelacje (zwłaszcza w klastrze 1) -> **warto zastosować PCA** przed tworzeniem modelu LDA.
- Drzewo decyzyjne najprawdopodobniej wybierze jako korzeń tylko jedną zmienną z pierwszego klastru - reszta nie wniesie żadnej nowej informacji.
- Ponieważ zmienne są skorelowane i opisują różne cechy w różnych jednostkach, należy wykonać **standaryzację danych** przed modelowaniem kNN.

Macierz korelacji predyktorów z grupowaniem (hclust)



Interpretacja modeli

You can add options to executable code like this

```
[1] 4
```

The `echo: false` option disables the printing of code (only output is displayed).